MIDTERM PROJECT GUIDE

BIG DATA AND ARTIFICIAL INTELLIGENCE | Weeks 1–7

End-to-End Big Data Analytics with PySpark: From Data Understanding to Evidence-Based Insights

Program Studi S1 Informatika · Fakultas Informatika · Telkom University

A. Tujuan

Mahasiswa menerapkan konsep Big Data, penyimpanan data, exploratory data analysis, preprocessing, dan PySpark dalam studi kasus berbasis dataset nyata. Penilaian menitikberatkan pada pemahaman proses, ketepatan implementasi, dan keterlacakan hasil; bukan sekadar akurasi model.

Capaian utama: Sub-CLO-12-2-1 (Mengaplikasikan Teknik AI dalam Analisis Data Besar). Capaian pendukung: Sub-CLO-12-1-1 (Mengaplikasikan Teknologi Big Data untuk Penyimpanan dan Pemrosesan Data). Bobot Mid-Term Project dalam RPS: 30% dari nilai mata kuliah; dilaksanakan pada minggu 7–8.

Minggu	Materi RPS	Bukti capaian dalam tugas
1	Review AI dan Machine Learning	Rumusan masalah dan pilihan jenis analisis
2	Karakteristik dan aplikasi Big Data	Profil dataset terhadap karakteristik Big Data
3	Non-relational database; SQL vs NoSQL	Perbandingan pilihan penyimpanan berbasis jenis data
4	Data collection/storage; warehouse vs lake	Diagram alur data dan argumen storage
5	EDA dan preprocessing	Profiling, visualisasi, validasi kualitas data
6	PySpark API, SQL, streaming, MLlib	Kode PySpark untuk transformasi dan analisis
7	Midterm case study	Laporan, notebook, presentasi dan demonstrasi

B. Ketentuan tugas

- Dikerjakan secara individu atau berpasangan (maksimal 2 mahasiswa). Durasi pengerjaan: 3 minggu, dilanjutkan presentasi/demonstrasi sesuai jadwal kelas.
- Gunakan satu dataset publik/terbuka dengan dokumentasi sumber, lisensi/ketentuan penggunaan, jumlah baris, jumlah kolom, ukuran, dan tanggal akses.

- Dataset disarankan berukuran ≥1 juta baris atau ≥500 MB data mentah. Dataset lebih kecil dapat disetujui bila kompleksitas dan alasan pemilihannya jelas. Tidak perlu memaksakan 3 GB; ukuran tidak otomatis membuktikan kompetensi.
- Pemrosesan utama wajib menggunakan PySpark DataFrame API dan Spark SQL. Pandas hanya untuk visualisasi data agregat atau sampel kecil yang dibatasi dan dijelaskan.
- Gunakan Google Colab, komputer lokal, atau lingkungan Spark lain. Dokumentasikan versi, konfigurasi Spark, penggunaan memori, dan kendala komputasi.
- Dilarang mengunggah data pribadi yang tidak dianonimkan. Penggunaan AI generatif diperbolehkan sebagai pendamping dengan deklarasi penggunaan dan verifikasi seluruh kode serta kesimpulan.

C. Skenario dan instruksi pengerjaan

1. Problem formulation & Big Data understanding (10 poin)

- Tetapkan satu pertanyaan utama dan minimal tiga pertanyaan analitis turunan; tentukan aktor pengguna hasil analisis dan keputusan yang akan dibantu.
- Jelaskan volume, variety, velocity, veracity, dan value berdasarkan bukti yang tersedia; velocity tidak boleh diklaim tinggi hanya karena dataset besar.

2. Data source, storage & architecture (15 poin)

- Buat data dictionary ringkas, gambarkan asal data dan pipeline: sumber → ingestion → storage → processing → output.
- Bandingkan SQL vs NoSQL dan data warehouse vs data lake untuk kasus Anda; pilih rancangan dengan alasan terkait struktur, pola akses, dan biaya/kompleksitas.
- Implementasi NoSQL atau streaming tidak wajib; tunjukkan rancangan yang konsisten dengan materi minggu 3–4.

3. PySpark data ingestion & processing (20 poin)

- Baca dataset dengan PySpark, tampilkan schema, record count, jumlah partisi, dan contoh data yang aman.
- Terapkan minimal lima operasi bermakna: select/filter, groupBy/aggregation, join bila relevan, kolom turunan, ordering, atau window operation. Sedikitnya dua pertanyaan dijawab juga dengan Spark SQL.
- Ukur waktu minimal dua operasi/pipeline menggunakan metode yang sama; jelaskan keterbatasan pengukuran (cache, I/O, hardware).

4. EDA & visualization (15 poin)

- Laporkan statistik deskriptif, missing values, duplikasi, nilai tak valid, distribusi, dan hubungan antaratribut sesuai tipe data.
- Buat minimal empat visualisasi berbeda yang menjawab pertanyaan analitik; setiap grafik memiliki judul, label, interpretasi, dan sumber agregasi.

5. Preprocessing & data quality validation (15 poin)

- Terapkan tindakan yang relevan untuk tipe data: casting, null handling, deduplication, outlier checks, encoding, atau feature engineering. Jelaskan alasan setiap tindakan dan jumlah record sebelum–sesudah.
- Buat minimal tiga pemeriksaan kualitas setelah transformasi; misalnya tidak ada ID duplikat, rentang nilai sah, dan schema sesuai.

6. Advanced analysis / ML baseline (10 poin)

- Lakukan satu analisis lanjutan dengan PySpark, misalnya segmentasi berbasis agregasi, pola temporal, ranking, atau satu baseline MLlib (classification/regression/clustering) jika relevan dengan kasus.
- Jika menggunakan ML: tentukan target, train/test split dengan seed tetap, metrik yang sesuai, dan hindari data leakage. Hyperparameter tuning bersifat opsional, bukan komponen wajib.

7. Interpretation, limitations & recommendations (5 poin)

- Berikan minimal tiga temuan yang langsung ditopang tabel/grafik; jelaskan setidaknya dua keterbatasan data/metode dan rekomendasi yang realistis.

8. Report, reproducibility & presentation (10 poin)

- Sertakan dokumentasi yang membuat penguji bisa menelusuri atau menjalankan ulang analisis. Paparkan peran tiap anggota jika berkelompok.

D. Bukti dan berkas yang dikumpulkan

- Laporan PDF 6–10 halaman (di luar lampiran): latar kasus, masalah, data, arsitektur, EDA, processing, hasil, keterbatasan, referensi.
- Notebook .ipynb berurutan yang dapat dijalankan ulang dari atas ke bawah, atau script .py + README yang memberikan prosedur eksekusi.
- README: tautan dataset, petunjuk memperoleh file, versi Python/PySpark, struktur folder, cara menjalankan, seed, dan daftar keterbatasan reproduksi.
- File presentasi maksimal 8 slide; presentasi 7 menit + tanya jawab/demo 5 menit. Tidak perlu melampirkan dataset penuh jika melebihi batas unggahan LMS.
- Lampiran individu: kontribusi nyata masing-masing anggota dan deklarasi bantuan AI generatif bila digunakan.

E. Rubrik penilaian (100 poin)

Komponen	Bobot	Indikator capaian penuh
Masalah & karakteristik Big Data	10	Pertanyaan terukur; 5V dinilai secara kritis berbasis bukti
Data source, storage & architecture	15	Provenance jelas; perbandingan SQL/NoSQL dan lake/warehouse; diagram logis

PySpark implementation	20	Kode berjalan; operasi relevan; Spark SQL dan API; pengukuran konsisten
EDA & visualization	15	Profiling memadai; ≥4 visualisasi valid dan diinterpretasikan
Preprocessing & validation	15	Langkah sesuai data; perubahan jumlah record; ≥3 quality checks
Analisis lanjutan/ML baseline	10	Metode tepat; hasil terukur; evaluasi sesuai bentuk analisis
Interpretasi & keterbatasan	5	≥3 temuan berbukti; ≥2 keterbatasan dan rekomendasi
Laporan, reproducibility dan video presentasi	10	Tuntas, bisa diaudit; demo dan kontribusi individu jelas
TOTAL	100	

Panduan pemberian skor per komponen: 100% bobot jika seluruh indikator terpenuhi dan dapat didemonstrasikan; 75% jika terdapat kekurangan minor; 50% jika sebagian substansi benar namun bukti kurang; 25% jika hanya upaya awal; 0% jika tidak dikerjakan/tidak dapat diverifikasi.

F. Tahapan pelaksanaan

Waktu	Target kerja	Bukti minimum
Minggu pengerjaan 1	Masalah, dataset, 5V, arsitektur	Proposal kasus 1 halaman dan schema dataset
Minggu pengerjaan 2	Ingestion, operasi PySpark, EDA, preprocessing	Notebook analisis dan quality checks
Minggu pengerjaan 3	Analisis, interpretasi, pelaporan	Notebook final, laporan, slide, README

G. Contoh topik studi kasus

Mobilitas/transportasi (tren perjalanan dan tarif); transaksi ritel (pola permintaan); kualitas udara/cuaca (pola waktu dan wilayah); ulasan produk (distribusi sentimen/ratings tanpa klaim model jika tidak dilatih); log akses (pola aktivitas dan anomali sederhana). Topik bebas sepanjang sesuai ketersediaan, legalitas, dan kualitas data.

H. Checklist sebelum pengumpulan

- ☐ Pertanyaan analitik dijawab dengan hasil yang dapat ditelusuri.
- ☐ Data provenance, lisensi, serta ukuran terdokumentasi.

- ☐ Notebook PySpark dan query SQL dapat dijalankan ulang.
- ☐ Perubahan akibat preprocessing dan quality checks ditunjukkan.
- ☐ Setiap visualisasi mendukung kesimpulan, bukan dekorasi.
- ☐ Sumber pustaka, penggunaan AI, dan peran anggota dinyatakan.